

Sistema de recomendación de películas basado en NLP

Informe de resultados — Trabajo Final Integrador

Introducción al PLN — LCD, ECyT UNSAM


Primer cuatrimestre 2026

De qué trata este informe

- Nos pidieron un sistema que, para cada uno de 14 usuarios, recomiende **5 películas** a partir de su historial y de una *query* en lenguaje natural.
- El enfoque es **basado en contenido**: representamos las películas por lo que dicen, no por lo que otros usuarios votaron.
- Implementamos y comparamos **dos estrategias de representación** de naturaleza distinta:
 - Estrategia 1 — **modelado de tópicos (LDA)**.
 - Estrategia 2 — **LLM local** (Ollama) con recuperación + reordenamiento.
- Este documento evalúa y justifica el modelo: qué funciona, qué no, y por qué.


Qué información tenemos para representar cada película

- Corpus de **4.967 películas** en español: sinopsis, keywords, género, año, director.
- Las tres señales de *contenido* no tienen nulos: sinopsis, keywords y género.
- Las **keywords** son el campo más rico: tags curados (*violencia doméstica, psycho-thriller*) que condensan el tema.
- Decisión: representamos cada película con sinopsis + keywords + género.



Qué condiciona el corpus a nuestras decisiones

- **Idioma mixto:** las keywords mezclan español e inglés → el preprocesamiento usa stopwords de ambos.
- **Nombres duplicados** (61) → trabajamos con un índice interno, no con el título.
- **Historial incompleto:** de 64 películas vistas, 7 no están en el corpus.
- Lo importante: esas ausencias **no son aleatorias**, caen todas en los perfiles ambiguos.



Consecuencia: los usuarios más difíciles de modelar son, además, los que menos historial conservan.

Por qué dos estrategias distintas

- La pregunta de fondo: ¿cómo hacer que películas similares queden cerca en el espacio, y que “similar” signifique lo mismo para el sistema y para el usuario?
- Elegimos dos representaciones que entienden la similitud de maneras opuestas:

	LDA (Estrategia 1)	LLM local (Estrategia 2)
Naturaleza	Tópicos latentes (probabilístico)	Razonamiento semántico
Similitud	Compartir tópicos	Compartir sentido / intención
Lectura	Transparente e interpretable	Caja negra con justificación

Estrategia 1 — modelado de tópicos con LDA

- Sobre sinopsis + keywords + género entrenamos un **LDA** de 20 tópicos (CountVectorizer + LatentDirichletAllocation, como en la Unidad 3).
- Cada película queda descrita como una **distribución de tópicos** θ (una mezcla, no una etiqueta única).
- Qué esperamos que capture: los *temas* del corpus (crimen, guerra, romance, ciencia ficción. . .) de forma interpretable.
- Ventaja sobre TF-IDF: no solo mide coincidencia de palabras, sino que agrupa vocabulario que aparece junto en un mismo tema.

Los tópicos que emergen

Tópico	Palabras más probables (interpretación)
T7	crimen, policial, agente, asesinato, FBI (<i>policial</i>)
T11	guerra, bélico, mundial, Vietnam (<i>bélico</i>)
T2	terror, suspenso, misterio, asesino, horror (<i>terror/thriller</i>)
T13	ciencia ficción, alienígenas, futuro, viaje (<i>sci-fi</i>)
T6	relaciones, romance, familia, hijos (<i>drama familiar</i>)
T10	animación, aventura, fantasía, animal (<i>animación</i>)

Los tópicos son legibles: esto es lo que hace defendible e interpretable a la estrategia.

Cómo representamos al usuario

- El **historial** y la **query** aportan información distinta:
 - historial = *qué le gustó* (distribución promedio de tópicos de lo que vio);
 - query = *qué quiere ahora* (la proyectamos al modelo con `lda.transform`).
- Perfil del usuario = $\alpha \cdot \text{tópicos}(\text{historial}) + (1 - \alpha) \cdot \text{tópicos}(\text{query})$.
- Recomendamos por **similitud coseno** en el espacio de tópicos, excluyendo lo ya visto.
- Si una película del historial no está en el corpus, se saltea (trabajamos con el df crudo).

Resultados LDA — un acierto y un caso difícil

Rodrigo (definido)

“hechos reales sobre corrupción o poder político”

- Tópicos del perfil: **T7 policial**, T0 biografía, **T11 bélico**.
- Recomienda: *Canción triste de Hill Street*, *Bajo el fuego* (bélico), *The Staircase* (documental crimen).
- Captura el eje *crimen/poder*, aunque pierde el matiz “basado en hechos reales”.


La diferencia no está en el modelo sino en la **señal**: el perfil ambiguo no apunta a un lugar único del espacio.

Paula (ambiguo)

“no quiero pensar mucho, algo intermedio”

- Tópicos del perfil: T17 romance/comedia, T5 documental — señales que se contradicen.
- Recomienda: *Antes de amanecer*, *Philadelphia*, *Tango para tres*: coherentes entre sí, pero la query casi no aporta dirección.

Evaluación de la Estrategia 1



- Sin *ground truth*, usamos una proxy: solapamiento de género entre recomendaciones e historial.
- Promedio **definidos 0.76** vs **ambiguos 0.42**.
- El sistema se comporta como esperábamos: más coherente donde hay señal clara.
- La métrica **no es igualmente válida** para todos: en los ambiguos el propio historial es contradictorio.

Del límite de LDA a la Estrategia 2

- LDA captura el *tema* pero no la *intención*: no entiende “algo que te haga pensar sobre qué es real” ni negaciones (“que no sea muy larga”).
- Estrategia 2 — **LLM local con Ollama** (Unidad 5), en dos pasos (esquema RAG):
 - ① **Recuperación**: TF-IDF preselecciona un *shortlist* de candidatos plausibles.
 - ② **Reordenamiento**: el LLM lee historial + query + sinopsis y elige las 5 finales con un **motivo**.
- Restringir al shortlist evita que el modelo *alucine* títulos fuera del corpus.
- Salida forzada a un **esquema Pydantic** (JSON parseable), como en la clase de Ollama.

Resultados de la Estrategia 2 (LLM)

Rodrigo (definido) — “*corrupción o poder político, basado en hechos reales*”

- *Buenas noches y buena suerte, El asesinato de Richard Nixon, La verdad oculta, El príncipe de la ciudad, La noche cae sobre Manhattan.*
- Motivo (*La verdad oculta*): “basada en hechos reales; denuncia el encubrimiento de abusos por parte de la ONU”.

Paula (ambiguo) — “*algo intermedio, ni vacío ni pesado*”

- *Beautiful Girls, Intimidación, Gintama, El último americano virgen, 2046.*
- Motivo (*Beautiful Girls*): “permite reflexionar sobre la vida sin sentirse abrumado”.

En Rodrigo el LLM capta el matiz “**basado en hechos reales**” que LDA no distinguía (4 de 5 son sobre corrupción real); en Paula verbaliza el “intermedio” que pedía, pero las elecciones quedan heterogéneas: cuando no hay señal, el LLM la *explica* mejor, no la *inventa*.

LDA frente a LLM

	LDA (tópicos)	LLM local
Qué compara	Tópicos compartidos	Significado / intención
Matices y negación	No los capta	Los interpreta
Interpretabilidad	Alta (tópicos legibles)	Baja, pero da un motivo
Reproducibilidad	Total (determinista)	No determinista
Costo	Milisegundos	Segundos por usuario
Riesgo	Tópicos difusos	Alucinar fuera de lista

No compiten: LDA da estructura interpretable; el LLM aporta comprensión de la query. Se complementan.

Límites del enfoque basado en contenido

- Hay un techo que **más datos del mismo tipo no resuelven**:
 - sin señal de otros usuarios, no hay descubrimiento por gustos parecidos (filtrado colaborativo);
 - una query vaga es vaga para cualquier representación;
 - evaluar sin *ground truth* obliga a proxies imperfectas.
- Lo que sí mejoraría: keywords más completas, sinopsis más largas, o señales de feedback del usuario.

Conclusión y recomendación

- Ambas estrategias **funcionan bien en perfiles definidos** y se degradan en los ambiguos: el límite es la señal, no el método.
- **Recomendación:** usar el **LLM** como recomendador principal por su lectura de la intención, con **LDA** como capa interpretable para explicar y auditar las recomendaciones.
- Para perfiles con poca señal, el sistema debería **pedir más información** antes que arriesgar una recomendación pobre.

¿Preguntas?